Konvolúciós Neurális Hálók és Vision Transformer architektúrák összehasonlítása felhőosztályozási feladatokra

Beszámoló a Deep Learning a gyakorlatban Python és LUA alapokon c. tárgyból

Kássa Kristóf
kassak@edu.bme.hu

Barancsuk Lilla
barancsuk.lilla@vik.bme.hu

2023. január 16.

Bevezetés

- Felhőképek osztályozása $\rightsquigarrow$ napelemek termelésének előrejelzése
- Neurális hálók képfeldologzásra: Konvolúciós Neurális Hálók (CNN) vs Vision Transfromerek (ViT)
- CNN
  - Konvolúciós és pooling rétegek halmaza
  - Minták keresése „csúszó" szűrők alkalmazásával
  - A kimeneti feature mapet az utolsó réteg osztályozza
  - Hagyományosan hang, kép, videó feldolgozásra
- ViT
  - A bemeneti képet pixelsorozatként kezeli
  - Pixelek közti kapcsolat $\rightsquigarrow$ *self-attention* mechanizmus
  - Hagyományosan szövegbányászatra alkalmazták (NLP)

Célkitűzés

- Felhőkép klasszifikálás CNN és ViT modellekkel
- A két architektúra tulajdonságainak és korlátainak megismerése
- Felépítésbeli és működésbeli különbségek vizsgálata
- Elvárt (korábbi kutatások) és saját eredmények összehasonlítása új adathalmazon
  - Számítási kapacitás igényeik
  - Futási idejük
  - Pontosságuk

Korábbi kutatások

- Transzformerek alkalmazása képfeldolgozási feladatokra
- CNN memória és számításigény szempontjából hatékonyabb (konvolúciós és pooling rétegek)
- A ViT modell „adatéhesebb", de pontosabb
- A CNN tanult jellemzőit könnyebb megérteni a szűrők vizualizálásával

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21K (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	**88.55** $\pm$ 0.04	87.76 $\pm$ 0.03	85.30 $\pm$ 0.02	87.54 $\pm$ 0.02	88.4/88.5*
ImageNet ReaL	**90.72** $\pm$ 0.05	90.54 $\pm$ 0.03	88.62 $\pm$ 0.05	90.54	90.55
CIFAR-10	**99.50** $\pm$ 0.06	99.42 $\pm$ 0.03	99.15 $\pm$ 0.03	99.37 $\pm$ 0.06	–
CIFAR-100	**94.55** $\pm$ 0.04	93.90 $\pm$ 0.05	93.25 $\pm$ 0.05	93.51 $\pm$ 0.08	–
Oxford-IIIT Pets	**97.56** $\pm$ 0.03	97.32 $\pm$ 0.11	94.67 $\pm$ 0.15	96.62 $\pm$ 0.23	–
Oxford Flowers-102	99.68 $\pm$ 0.02	**99.74** $\pm$ 0.00	99.61 $\pm$ 0.02	99.63 $\pm$ 0.03	–
VTAB (19 tasks)	**77.63** $\pm$ 0.23	76.28 $\pm$ 0.46	72.72 $\pm$ 0.21	76.29 $\pm$ 1.70	–
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

Forrás: Dosovitskiy, Alexey, et al. "An image is worth 16x16 words: Transformers for image recognition at scale."

Felhasznált adatsor

- Adathalmaz forrás: Swimcat-extend dataset (nyílt adatbázis)
- 2100 különböző kép, 6 különböző típusú égbolt, figyelembe véve a felhőzetet
- Kategóriánként 350 db kép
- A tanítás előtt a képeket normalizáltuk és 224x224 méretűre formáztuk
- Egyszerű statisztikai tulajdonságok alapján nem megkülönböztethető kategóriák

A–Clear sky

B–Patterned clouds

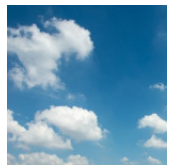

C–Thin white clouds

D–Thick white clouds

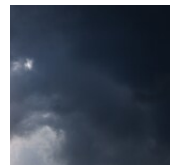

E–Thick dark clouds

F–Veil clouds

A hálók felépítése

- Bemeneti réteg
- Opcionális adatdúsítás (augmentation layer)
  - Nincs adatdúsítás
  - Véletlen forgatás
  - Véletlen forgatás, tükrözés és zoom
- **Előtanított model (CNN vagy ViT, tanítható vagy rögzített súlyok)**[1]
- Dropout réteg
- Kimeneti réteg

Konvolúciós neurális háló (CNN)

- EfficientNetB1[2] $(7 \cdot 10^6)$
- ResNet18D[2] (10^7)

Vision Transformer (ViT)

- vit_tiny_patch16_224[2] $(5 \cdot 10^6, 16)$
- vit_tiny_r_s16_p8_224_in21k[2] $(10^7, 88)$

[1] A hálókat az ImageNet-21k adatbázison előtanították

[2] Tensorflow Image Models

Vizsgált modellkonfigurációk, kísérleti módszertan

	Paraméterek száma	Háló taníthatósága	Adatdúsítás	CNN modell	ViT modell
1	$5 \cdot 10^6$	rögzített	nincsen	cnn_5m_f_na	vit_5m_f_na
2			alacsony	cnn_5m_f_la	vit_5m_f_la
2			magas	cnn_5m_f_ha	vit_5m_f_ha
4	$5 \cdot 10^6$	tanítható	magas	cnn_5m_t_ha	vit_5m_t_ha
5	10^7	tanítható	magas	cnn_10m_t_ha	vit_10m_t_ha

Kísérleti módszertan

- 5-szörös keresztvalidáció minden modellre
- 400 epoch tanítás + validáció
- Adam optimizer, $lr = 3 \cdot 10^{-5}$
- Early stopping 20 epoch után

Eredmények értékelése: pontosság alakulása a tanítás során

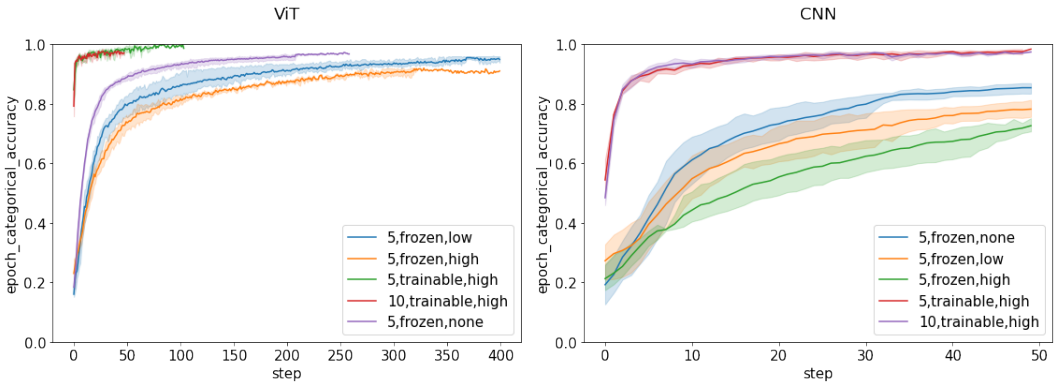

Eredmények értékelése: maximális elért validációs pontosság

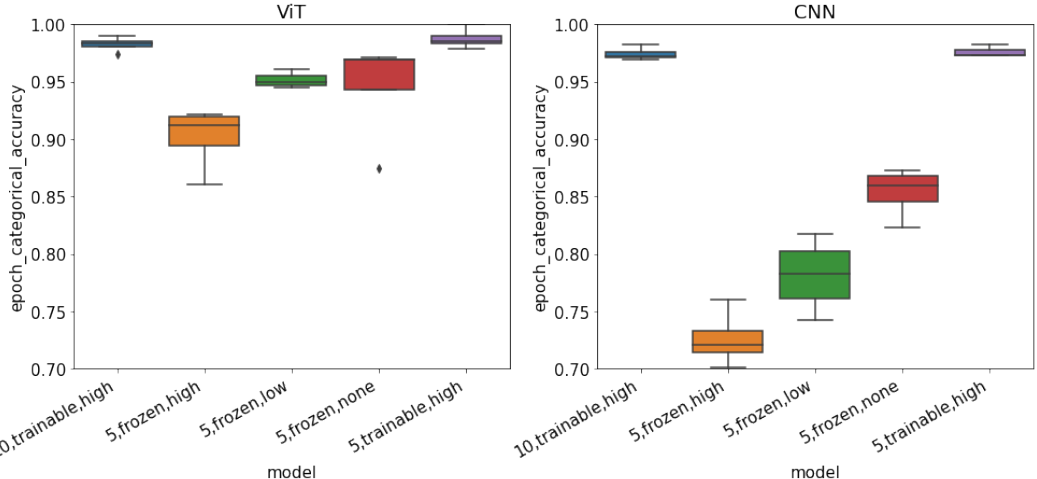

Eredmények értékelése: független tesztadatsor

Model neve	Pontosság [%]	Veszteség
vit_10m_ha_t	77	1,52
cnn_5m_ha_t	74	1,12
vit_5m_ha_t	72	1,67
cnn_10m_ha_t	63	1,20
vit_5m_ha_f	56	1,60
vit_5m_la_f	50	2,56
vit_5m_na_f	43	3,42
cnn_5m_na_f	42	1,60
cnn_5m_ha_f	39	1,60
cnn_5m_la_f	37	1,61

Modellek performanciájának összehasonlítása

Modell	FLOPS (gigaFLOPS)	Paraméterek száma (millió)	Maximum pontosság [%]
vit_5m_ha_t	162	5,7	1,0
vit_10m_ha_t	56	10,5	0,99
cnn_5m_ha_t	75	7,8	0,98
cnn_10m_ha_t	263	11,7	0,98
vit_5m_na_f	162	5,7	0,97
vit_5m_la_f	162	5,7	0,96
vit_5m_ha_f	162	5,7	0,92
cnn_5m_na_f	75	7,8	0,87
cnn_5m_la_f	75	7,8	0,81
cnn_5m_ha_f	75	7,8	0,76

Összefoglalás

- Cél: képfeldolgozási célú neurális háló architektúrák összehasonlítása
- Probléma: felhőképek osztályozása
- Változatos paraméterű modellek
- Modellek értékelése 5-szörös keresztvalidációval
- Performancia és pontosság vizsgálata

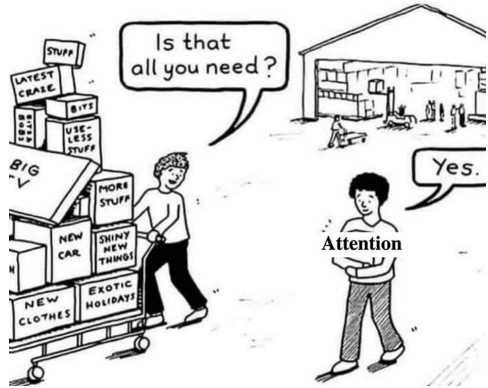

Vaswani, Ashish, et al. "Attention is all you need." *Advances in neural information processing systems 30* (2017) - cited more than 62000 times

Veszteség alakulása a tanítás során

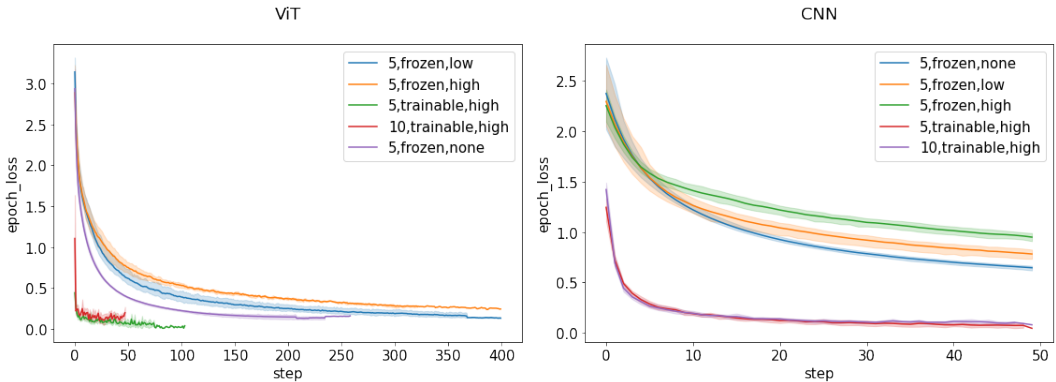

Különböző modellek veszteségének összehasonlítása